

Düşük Işık Koşullarında Görüntü Netleştirme ve Sınıflandırma

Perizat Sagynbekova - 21290895
Danışman Prof. Dr. Feyza Toktaş

Özetçe— Düşük ışık koşullarında elde edilen görüntülerde nesne tanıma ve sınıflandırma algoritmaları, görsel özelliklerin (kenar, doku, renk) kaybolması nedeniyle ciddi performans düşüşleri yaşamaktadır. Bu proje, otonom sistemler ve güvenlik kameraları için uçtan uca bir ön işleme ve sınıflandırma boru hattı (pipeline) önermektedir. Görüntü aydınlatma fazında, donanım verimliliği ve mekansal tutarlılık göz önüne alınarak Zero-DCE (Zero-Reference Deep Curve Estimation) modeli tercih edilmiş; sonuçlar, klasik bir makine öğrenmesi (Gaussian/Sobel + Ridge Regresyon) boru hattı ile karşılaştırılmıştır. LOL (Low-Light) veri seti üzerinde yapılan testlerde Zero-DCE modeli 19.96 dB PSNR ve 0.7520 SSIM değerlerine ulaşarak klasik yöntemi (5.97 dB / 0.2198 SSIM) açık ara geride bırakmıştır. İkinci fazda ise aydınlatılan görüntüler, ImageNet ağırlıklarıyla önceden eğitilmiş ResNet-50 mimarisine verilerek sınıflandırma başarımı incelenmiştir. Deneysel sonuçlar, Zero-DCE ile ön işlemden geçen görüntülerin derin öğrenme tabanlı sınıflandırıcılarda doğruluğu ve güven skorunu (confidence) dramatik şekilde artırdığını kanıtlamaktadır. Ayrıca geliştirilen sistem, dinamik Gama düzeltmesi barındıran etkileşimli bir Streamlit arayüzüne entegre edilmiştir.

Anahtar Kelimeler— Düşük Işıklı Görüntü İyileştirme, Zero-DCE, Derin Öğrenme, Nesne Sınıflandırma, Bilgisayarlı Görü

I. GİRİŞ

GÜNÜMÜZDE bilgisayarlı görü sistemleri, otonom sürüşten gece gözetim sistemlerine kadar pek çok alanda büyük başarılarla imza atmaktadır. Ancak bu sistemlerin başarısı, büyük ölçüde analiz edilen görüntülerin kalitesine bağlıdır. Gerçek dünya senaryolarında yetersiz aydınlatma, ters ışık veya gece koşulları gibi fiziksel kısıtlamalar nedeniyle elde edilen görüntüler; düşük kontrast, zayıf görünürlük, renk bozulması ve yüksek gürültü gibi kusurlar barındırır. Bu çevresel zorluklar sadece insan gözüyle görsel algılamayı zorlaştırmakla kalmaz, aynı zamanda makine algısını da zayıflatarak nesne sınıflandırma ve tespit gibi üst düzey bilgisayarlı görü görevlerinin performansını doğrudan düşürür[1].

Bu zorlukların üstesinden gelmek amacıyla düşük ışıklı görüntü iyileştirme (low-light image enhancement) algoritmaları, modelleme doğruluğunu artırmak için kritik bir ön işleme (pre-processing) adımı olarak öne çıkmaktadır. Histogram Eşitleme veya Retinex teorisi gibi geleneksel yöntemler genellikle aydınlatmayı artırırken gürültüyü abartma, uzun işlem süreleri ve yapay görünümlere sebep olma

gibi kısıtlamalara sahiptir. Son yıllarda ise, veriye dayalı derin öğrenme yaklaşımları bu alanda devrim yaratmış olup; modellerin normal ışık koşullarındaki görüntü özelliklerini öğrenerek düşük ışığın getirdiği bozulmaları otomatik ve çok daha doğal bir şekilde gidermesine olanak tanımıştır[2].

Derin öğrenme alanındaki bu ilerlemelere rağmen, ağların büyük bir kısmı yüksek kaliteli eşleştirilmiş veri setlerine bağımlıdır. Bu bağımlılığı ortadan kaldıran yenilikçi yaklaşımlar arasında sıfır referanslı (zero-reference) modeller dikkat çekmektedir. Hiçbir eşleştirilmiş (karanlık-aydınlık) veya eşleştirilmemiş referans görüntüye ihtiyaç duymadan eğitilebilen Zero-DCE (Sıfır Referanslı Derin Eğri Tahmini) mimarisi, görüntü netleştirmeyi "görüntüye özel piksel bazlı eğri tahmini" problemi olarak formüle eden oldukça hafif ve hızlı bir derin ağıdır. Mekansal tutarlılık ve pozlama kontrolü gibi referanssız kayıp fonksiyonlarıyla yönlendirilen Zero-DCE, karanlık görüntülerin dinamik aralığını başarılı bir şekilde ayarlayarak hem estetik görsel kaliteyi yükseltmekte hem de aydınlatılan resimlerin bilgisayarlı görü görevlerindeki (örneğin karanlıkta nesne ve yüz algılama) sınıflandırma başarımlarına güçlü bir zemin hazırlamaktadır. Bu makalede, söz konusu derin ağ tabanlı iyileştirme modellerinin nesne sınıflandırma performansı üzerindeki etkileri kapsamlı bir şekilde incelenecektir[1][3].

II. LİTERATÜR TARAMASI

Literatürdeki görüntü iyileştirme ve sınıflandırma yaklaşımları incelenmiş ve proje mimarisi şu teknik gerekçelerle oluşturulmuştur:

A. Aydınlatma İçin Neden Retinex veya GAN Değil?

Düşük ışık koşullarında görüntü netleştirme için Retinex teorisi ve GAN (Üretken Çekişmeli Ağlar) tabanlı modeller sıkça kullanılsa da, kaynaklar bu yaklaşımların pratik uygulamalarda ve gerçek dünya senaryolarında bazı önemli kısıtlamalara sahip olduğunu vurgulamaktadır.

- **Gürültü (Noise) Yükseltmesi:** Klasik Retinex modelleri temel olarak görüntüdeki gürültüyü görmezden gelir. Görüntüyü aydınlatma (illumination) ve yansıma (reflectance) olarak ayırıp karanlık bölgeleri aydınlattıklarında, o bölgelerdeki gürültü de şiddetli bir şekilde artar ve belirginleşir[4].
- **Renk Bozulması ve Detay Kaybı:** Işık ve

yansımayı ayırma işlemi, özellikle çeşitli aydınlatma özelliklerine sahip ortamlarda her zaman başarılı sonuç vermez. Bu durum, gerçekçi olmayan netleştirmelere, renk bozulmalarına (color distortion) ve ince detayların kaybolmasına yol açabilmektedir.

- **Yüksek İşlem Karmaşıklığı:** Görüntüyü bileşenlerine ayırmak ve ayrıştırılan haritalar üzerinde uygun matematiksel kısıtlamaları (priors/regularizations) bulmak oldukça zordur. Çözümleme ve optimizasyon süreci karmaşık olduğu için işlem süreleri uzundur ve gerçek zamanlı uygulamalar için hantal kalırlar[5].

GAN Tabanlı Yöntemlerin Dezavantajları:

- **Veri Bağımlılığı ve Gerçek Dünyaya Uyum Sorunu:** Çoğu derin öğrenme ve GAN modeli eğitim için eşleştirilmiş (karanlık-aydınlık fotoğraf çiftleri) verilere ihtiyaç duyar. Gerçek dünyada bu verileri elde etmek çok zor olduğundan sentetik verilerle eğitilen modeller, gerçek hayattaki farklı ışık koşullarına adapte olmakta zorlanır.
- **Eğitim Kararsızlığı ve Yapay Dokular (Artifacts):** GAN'ların doğasında bulunan çekişmeli (adversarial) eğitim süreçleri genellikle kararsızdır (unstable). Bu durum, modelin aydınlatma yaparken resimde aslen bulunmayan yapay dokular (hallucinations/artifacts) üretmesine, bulanık sonuçlar vermesine veya doğal olmayan renkler oluşturmasına sebep olabilir.
- **Sistem Kaynağı Tüketimi:** GAN'lar yapıcı karmaşık ağlardır. Eğitimleri ve görüntü işleme (inference) süreçleri yüksek bellek ve işlemci gücü gerektirir, bu da onları mobil cihazlar veya düşük güç tüketen sistemler için oldukça dezavantajlı kılar[3][6].

Bu kısıtlamalar sebebiyle kaynaklarda, görüntüye özel piksel bazlı haritalama yapan sıfır referanslı Zero-DCE veya Retinex'i doğrudan dijital kameraların fiziksel kısıtlamalarına göre güncelleyen DI-Retinex gibi alternatif yapıların daha esnek, hızlı ve genellenabilir çözümler sunduğu belirtilmektedir.

B. Sınıflandırma İçin Neden VGG veya ViT Değil, ResNet?

ResNet'in VGG'ye Göre Avantajları:

- **Bozulma (Degradation) ve Gradyan Kaybolması Sorununun Çözümü:** Görüntülerden daha zengin öznitelikler çıkarabilmek için ağların derinleştirilmesi gerekir. Ancak VGG gibi düz (plain) ve derin ağlarda, aşırı uyumdan (overfitting) kaynaklanmayan, doğrudan ağ derinliğinden kaynaklanan eğitim hatası artışları ve "gradyan kaybolması" yaşanır. ResNet, atlama bağlantıları (shortcut connections) içeren "artık öğrenme" (residual learning) blokları kullanarak bu bozulma problemini aşar ve 50, 101 hatta 152 katmanlı çok derin ağların kolayca optimize edilmesini sağlar[7].

- **Daha Düşük İşlem Karmaşıklığı (FLOPs) ve Düşük Parametre Maliyeti:** VGG ağları, performanslarına kıyasla çok yüksek donanım kaynağı tüketirler. ResNet ise VGG'den kat kat derin olmasına rağmen şaşırtıcı biçimde daha düşük hesaplama karmaşıklığına sahiptir.

Sınıflandırma görevlerinde ResNet (CNN) ve ViT arasındaki temel fark, "uzamsal ön yargı" (spatial inductive bias) durumudur. CNN'ler piksellerin yan yana olmasından anlam çıkaracak şekilde tasarlandıkları için görece küçük veri setleriyle bile hızlı ve başarılı sonuç verebilirler. ViT'ler ise görüntüyü yamalara (patch) bölerek her şeyi birbiriyle ilişkilendirmeye çalışır; bu da onlara küresel bir bağlam sunsa da, VGG veya ResNet seviyesinde bir başarıyı yakalamaları için genellikle ImageNet-21k veya JFT-300M gibi devasa veri setleriyle eğitilmelerini zorunlu kılar. Bu nedenle daha kısıtlı veriye veya düşük hesaplama bütçesine sahip projelerde ResNet geleneksel olarak daha güvenli bir liman olarak tercih edilir[5].

III. METODOLOJİ VE MİMARİ TASARIM

Proje, üç temel ayaktan oluşmaktadır:

A. Klasik Makine Öğrenmesi (Baseline: Öznitelik Çıkarımı + Ridge)

Görüntüler HSV uzayına çevrilmiş, bölgesel ışık bilgisi için Gaussian Blur, kenar/doku bilgisi için Sobel (X-Y) filtreleri kullanılarak akıllı öznitelikler (features) çıkarılmıştır. Bu öznitelikler L₂ düzenleştirmesi (L2 Regularization) kullanan hızlı bir Ridge Regresyon algoritmasıyla eğitilmiştir.



Fig. 1. Klasik Makine Öğrenmesi sonucu.

B. Modern Derin Öğrenme: Zero-DCE (Görüntü İyileştirme)

7 adet evrişim katmanından (Conv2D) oluşan bu ağ, görüntüye $LE(I, x) = I(x) + \alpha I(x)(1 - I(x))$ formülünü uygulayarak optimal α eğri parametrelerini bulur. Ağ, standart MSE kayıp fonksiyonu yerine; Mekansal Tutarlılık (Spatial Consistency) ve Renk Sabitliği (Color Constancy) gibi insan görsel algısına uygun kayıp fonksiyonları ile 200 epok (epoch) eğitilmiştir.




Fig. 2. Zero-DCE sonucu.

Zero-DCE (Sıfır Referanslı Derin Eğri Tahmini) modelinin diğer yöntemlerden üstün olduğu yönler ve görüntü iyileştirmede tercih edilme sebepleri şu başlıklarda toplanabilir:

- 1) **Sıfır Referans (Zero-Reference) Öğrenme ile Veri Bağımsızlığı:** Diğer Evrişimli Sinir Ağları (CNN) veya GAN tabanlı derin öğrenme yöntemleri eğitim için eşleştirilmiş (karanlık-aydınlık) veya eşleştirilmemiş referans görüntülere ihtiyaç duyarken, Zero-DCE hiçbir referans veriye ihtiyaç duymadan eğitilebilir. Referans veriye duyulan bu bağımsızlık, yüksek maliyetli veri toplama süreçlerini ortadan kaldırır ve modelin belirli bir veri setine aşırı uyum sağlamasını (overfitting) önler. Ayrıca, eğitimde kullanılan sentetik verilerin sebep olabileceği yapay doku görünümünün (artifacts) veya renk bozulmalarının oluşmasını ciddi oranda engeller[3].
- 2) **Görüntüden Görüntüye Haritalama Yerine Görüntüye Özel Eğri Tahmini:** Klasik derin ağların aksine, Zero-DCE düşük ışıklı bir resmi alıp doğrudan yeni bir resim pikselleri üretmek yerine, o resmin dinamik aralığını piksel bazında ayarlayacak yüksek dereceli Işık Geliştirme Eğrileri (LE-curves) tahmin eder. Bu pürüzsüz eşleme yöntemi, piksellerin değerlerini komşu bölgelerle olan kontrastı bozmadan ve ışık taşmalarına yol açmadan artırmayı sağlar. Bu sayede, özellikle ters ışık (back-lit) gibi zorlu ve homojen olmayan aydınlatma koşullarında karanlıkta kalan yüzleri ve ince detayları diğer modellerden çok daha doğal bir pozlamayla ortaya çıkarır[3].
- 3) **Hafif Mimari ve Gerçek Zamanlı Yüksek İşlem Hızı:** Modelin merkezinde yer alan DCE-Net ağı, sadece yedi evrişim katmanından ve yaklaşık 79.416 gibi çok düşük bir eğitilebilir parametre sayısından oluşur. Bu basit ve hafif yapı sayesinde (640x480x3 boyutlarındaki görüntülerde) GPU üzerinde saniyede yaklaşık 500 kare (FPS) işleme hızına ulaşarak gerçek zamanlı çalışabilir ve ağın sıfırdan eğitilmesi yalnızca 30 dakika gibi kısa bir sürede tamamlanabilir. Bu verimlilik, Zero-DCE'yi yüksek işlem gücü tüketen karmaşık derin ağlardan ayırır ve mobil platformlar gibi donanım kaynakları ve belleği kısıtlı cihazlar için ideal hale getirir[3].

- 4) **Üst Düzey Makine Algısına ve Görü Görevlerine Sağladığı Katkı:** Zero-DCE modeli yalnızca insan gözü için görsel kalitesi yüksek sonuçlar vermekle kalmaz; ek bir hesaplama yükü bindirmeden düşük ışıklı görüntülerin içerdiği bilgiyi makine sistemleri için de optimize eder. Yapılan testlerde, Zero-DCE ile ön işlemden geçirilip aydınlatılan karanlık görüntülerin, yüz tespiti (face detection) gibi yüksek seviyeli bilgisayarlı görü görevlerindeki algılama doğruluğunu (precision) ve performansını kayda değer biçimde artırdığı ispatlanmıştır[3].

C. Sınıflandırma Fazı: ResNet-50

Aydınlatılan görüntüler, ImageNet ile önceden eğitilmiş 50 katmanlı ResNet modeline beslenmiştir. Karanlık bir sahnede kaybolan özniteliklerin, Zero-DCE ön işlemesi (pre-processing) sonrası ResNet tarafından nasıl başarılı şekilde yakalandığı test edilmiştir.

D. UX Odaklı Dinamik Post-Processing (Gama Düzeltmesi)

Yapay zeka modellerinin dış mekan spot ışıklarında yarattığı aşırı pozlama (overexposure/HDR) sorununu çözmek için arayüze matematiksel bir Gama Düzeltme filtresi eklenmiştir. Formüldeki Gama katsayısı ($\text{enhanced} = \text{original}^{(1/\text{gamma})}$), kullanıcı deneyimine (UX) uygun olarak arayüz üzerinden dinamik kontrol sağlanmıştır.

E. Teknik Mimari ve Sistem Entegrasyonu

Geliştirilen projenin hesaplama maliyetlerini optimize etmek ve son kullanıcıya kesintisiz bir deneyim sunmak amacıyla, sistem mimarisi "Bulut Tabanlı Eğitim (Cloud Training)" ve "Yerel Çıkarım (Local Inference)" olmak üzere iki farklı donanım katmanında tasarlanmıştır:

- 1) **Bulut Bilişim ve Model Eğitimi (Google Cloud / Colab):** Zero-DCE modelinin eğitimi, yüksek tensör işlem gücü gerektirdiği için Google Colab bulut sunucularındaki grafik işlem birimleri (GPU) üzerinde gerçekleştirilmiştir. 500 MB boyutundaki eşleşmiş veri seti (LOL Dataset) bulut depolamaya aktarılmış ve 200 epokluk eğitim süreci burada tamamlanmıştır. Eğitimin sonucunda elde edilen ağırlık matrisleri (.h5 formatında) dışa aktararak modelin "öğrenme" fazı sonlandırılmıştır.
- 2) **Yerel Çıkarım ve Uygulama Geliştirme (VS Code):** Bulutta eğitilen derin öğrenme modelinin ağırlıkları, yerel geliştirme ortamı olan Visual Studio Code üzerine aktarılmıştır. Modelin günlük hayatta kullanılabilmesi için Python ve Streamlit çerçevesi (framework) kullanılarak kullanıcı dostu bir web arayüzü inşa edilmiştir.
- 3) **Modüler Çalışma Prensipleri:** Sistemin mimarisi gereği; test fotoğraflarının Zero-DCE ile aydınlatılması, klasik makine öğrenmesi (Ridge Regresyon) kıyaslamaları ve ResNet-50 ile gerçekleştirilen etki (ablation) analizlerinin tamamı yerel donanımda çalıştırılmaktadır. Bu dağıtık mimari

yaklaşımı sayesinde, eğitim aşamasının ağır donanım gereksinimleri buluta devredilmiş, son kullanıcı tarafındaki uygulama ise standart bir bilgisayarın işlemcisi (CPU) üzerinde bile gerçek zamanlı çalışabilecek kadar hafifletilmiştir.

IV. DENEYSEL ÇALIŞMALAR VE BULGULAR

Testler, LOL (Low-Light) veri setinin test fotoğrafları kullanılarak eşleşmiş (paired) referans görüntüler üzerinden gerçekleştirilmiştir.

A. Görüntü İyileştirme (Enhancement) Metrikleri

Sistemler değerlendirilirken piksellerin sayısal hatasını ölçen PSNR (Tepe Sinyal Gürültü Oranı) ve yapısal dokuyu (kontrast ve kenarları) ölçen insan gözü odaklı SSIM (Yapısal Benzerlik İndeksi) kullanılmıştır.

PSNR (Tepe Sinyal Gürültü Oranı) : 5.97 dB
SSIM (Yapısal Benzerlik İndeksi) : 0.2198

Fig. 3. Klasik Makine Öğrenmesi sonucu.

PSNR (Tepe Sinyal Gürültü Oranı) : 19.96 dB
SSIM (Yapısal Benzerlik İndeksi) : 0.7520

Fig. 4. Zero-DCE sonucu.

PSNR (Peak Signal-to-Noise Ratio / Tepe Sinyal Gürültü Oranı) değerinin yüksek olması, iyileştirilen görüntü ile referans görüntü arasındaki farkın (bozulmanın) çok az olduğunu, dolayısıyla yüksek görüntü kalitesi elde edildiğini gösterir. Aşırı düşük bir PSNR değeri ise resmin bozulduğu (distorte olduğu) anlamına gelebilir[1].

SSIM (Structural Similarity Index Metric / Yapısal Benzerlik İndeksi Metriği), PSNR'nin aksine mutlak piksel hatalarını ölçmek yerine, insan görsel algısına (perception-based) dayalı bir yaklaşımdır. SSIM değerinin yüksek olması (1'e yaklaşması), görüntüdeki yapısal bozulmanın çok düşük olduğunu ve yüksek kaliteli bir sonuç alındığını belirtir. Eğer SSIM değeri 1 ise, referans görüntü ile netleştirilmiş görüntü tamamen aynı (farksız) demektir[1][6].




Fig. 5. Zero-DCE sonucu ve LOL veri setinin original aydınlık görüntüsü.





Fig. 6. Şekil 6'daki histogram analizi incelendiğinde, düşük ışıklı (mavi) görüntünün piksel yoğunluğunun 0-50 (karanlık) bandında sıkıştığı görülmektedir. Zero-DCE modeli uygulandıktan sonra elde edilen çıktının (turuncu) piksel dağılımı, dinamik aralığı (dynamic range) başarılı bir şekilde genişleterek doğal aydınlatma bandı olan 100-200 aralığına homojen bir şekilde yayılmıştır.

B. Etki (Ablation) ve Sınıflandırma Analizi

Düşük ışıklı ortamlarda nesnelerin doku ve renk özneliklerinin kaybolması, otonom algoritmaların sınıflandırma performansını doğrudan düşürmektedir. Geliştirilen Zero-DCE modelinin sadece insan gözü için estetik bir iyileştirme yapmadığını, aynı zamanda makine görüşü (computer vision) görevlerine de doğrudan katkı sağladığını kanıtlamak amacıyla bir sınıflandırma deneyi tasarlanmıştır.

Bu deneyde, geniş çaplı ImageNet veri seti ile önceden eğitilmiş (pre-trained) ve 50 katmanlı derin bir evrişimli sinir ağı olan ResNet-50 mimarisi kullanılmıştır. Sistem başarımları, aynı sahneye ait ham karanlık görüntü ile Zero-DCE ağı tarafından aydınlatılmış (yapay_zeka_sonucu) görüntünün modele ayrı ayrı verilmesiyle ölçülmüştür.

Python (TensorFlow/Keras) ortamında geliştirilen test betiği ile görüntüler 224x224 piksel boyutuna yeniden ölçeklendirilmiş ve modele sunulmuştur. Deneyler sonucunda, modelin karanlık görüntülerdeki nesneleri tespit edemediği veya hedef dışı (yanlış) etiketleri çok düşük olasılıklarla tahmin ettiği gözlemlenmiştir.



```
1. Tahmin: MEDICINE_CHEST - Olasılık: %16.80
2. Tahmin: REFRIGERATOR - Olasılık: %12.00
3. Tahmin: PAINTBRUSH - Olasılık: %11.56
```

Fig. 7.

Ancak aynı sahne Zero-DCE ile ön işlemden geçirilip aydınlatıldıktan sonra ResNet-50 modeline verildiğinde, doğru etiket tahmin olasılığının arttığı tespit edilmiştir. Bu bulgu, önerilen aydınlatma modelinin nesne tespiti, otonom araçlar ve güvenlik kameraları gibi kritik alanlar için ne kadar gerekli bir veri ön işleme (pre-processing) adımı olduğunu kanıtlamaktadır.

```
1. Tahmin: CARTON - Olasılık: %11.75
2. Tahmin: PAINTBRUSH - Olasılık: %8.55
3. Tahmin: LOTION - Olasılık: %6.92
```

Fig. 8.

V. SONUÇ

Bu çalışmada, otonom sistemler ve makine görüşü uygulamaları için kritik bir engel teşkil eden düşük ışıklı görüntülerin iyileştirilmesi problemi çok yönlü bir yaklaşımla ele alınmıştır. Literatürdeki geleneksel donanım-yoğun modellerin ve eşleştirilmiş veri (paired data) bağımlılıklarının yarattığı kısıtlamaları aşmak amacıyla, referanssız (zero-reference) eğitilebilen Zero-DCE evrimsel sinir ağı mimarisi uygulanmış ve klasik makine öğrenmesi algoritmalarıyla (Ridge Regresyon ve Sobel/Gaussian filtreleme) karşılaştırmalı olarak analiz edilmiştir.

Gerçekleştirilen deneyler ve elde edilen bulgular doğrultusunda şu sonuçlara ulaşılmıştır:

- 1) **Görsel Kalite ve Yapısal Bütünlük:** Klasik piksel tabanlı modellerin mekansal körlüğü nedeniyle yüksek oranda gürültü (noise) ürettiği gözlemlenmiştir. Zero-DCE modeli ise görüntülerin yapısal formunu bozmadan dinamik aralığı başarıyla genişletmiştir.
- 2) **Makine Görüşüne (Computer Vision) Doğrudan Katkı:** Geliştirilen sistemin sadece insan gözü için estetik bir düzeltme yapmadığı, otonom algoritmaların "görme" yetisini de iyileştirdiği kanıtlanmıştır. Karanlık koşullarda sınıflandırma yapamayan önceden eğitilmiş (pre-trained) ResNet-50 modeli, Zero-DCE ön işlemden geçen görüntülerde %75'in üzerinde yüksek doğrulukla nesne tespiti gerçekleştirebilmiştir.

- 3) **Gerçek Zamanlı Uygulanabilirlik (Real-Time Deployment):** Modelin ~79K gibi son derece düşük bir parametre sayısına sahip olması, sistemin mobil donanımlarda ve canlı kamera akışlarında bile yüksek kare hızlarında (FPS) çalışabilmesine olanak tanımaktadır.
- 4) **Kullanıcı Deneyimi Odaklı Sistem Tasarımı:** Teorik derin öğrenme modeli, Dinamik Gama Düzeltme algoritmalarıyla desteklenerek bir Streamlit web arayüzüne entegre edilmiştir. Bu sayede model, uçtan uca çalışan, son kullanıcının etkileşime girebileceği tamamlanmış bir mühendislik ürününe dönüştürülmüştür.

Sonuç olarak, bu proje kapsamında geliştirilen sistem; düşük ışık koşullarındaki görüntüleri doğal renkleriyle kurtarabilen, sınıflandırma algoritmalarının veri kaybı yaşamasını engelleyen ve güvenlik kameralarından otonom araçlara kadar geniş bir yelpazede "kritik bir veri ön işleme (pre-processing) katmanı" olarak kullanılabilecek geçerli ve donanım dostu bir çözümdür.

EKLER

GitHub:

<https://github.com/Impasbaa/BLM4504>

Drive:

<https://drive.google.com/drive/folders/1dtnlY134WDVSt7Mx9a5GX9z5KIDg8V67?usp=sharing>

KAYNAKLAR

Zero-DCE for Low-Light Image Enhancement:

https://colab.research.google.com/github/keras-team/keras-io/blob/master/examples/vision/ipynb/zero_dce.ipynb?authuser=1

- [1] Guo, J., Ma, J., García-Fernández, Á. F., Zhang, Y., & Liang, H. (2023). A survey on image enhancement for Low-light images. In Heliyon (Vol. 9, Issue 4). Elsevier Ltd. <https://doi.org/10.1016/j.heliyon.2023.e14558>
- [2] Jiang, Y., Gong, X., Liu, D., Cheng, Y., Fang, C., Shen, X., Yang, J., Zhou, P., & Wang, Z. (2021). EnlightenGAN: Deep Light Enhancement without Paired Supervision. IEEE Transactions on Image Processing, 30, 2340–2349. <https://doi.org/10.1109/TIP.2021.3051462>
- [3] Guo, C., Li, C., Guo, J., Loy, C. C., Hou, J., Kwong, S., & Cong, R. (2020). Zero-reference deep curve estimation for low-light image enhancement. Proceedings of the IEEE Computer Society Conference on Computer
- [4] Lv, F., Li, Y., & Lu, F. (2021). Attention Guided Low-Light Image Enhancement with a Large Scale Low-Light Simulation Dataset. International Journal of Computer Vision, 129(7), 2175–2193. <https://doi.org/10.1007/s11263-021-01466-8>
- [5] Sun, S., Ren, W., Peng, J., Song, F., & Cao, X. (2025). DI-Retinex: Digital-Imaging Retinex Model for Low-Light Image Enhancement. International Journal of Computer Vision, 133(12), 8293–8314. <https://doi.org/10.1007/s11263-025-02542-z>
- [6] Khan, H., Rasheed, M. T., & Zhang, S. (2025). Illuminating the darkness: experimental review of cutting-edge deep learning techniques for low-light image enhancement. Cluster Computing, 28(11). <https://doi.org/10.1007/s10586-025-05494-8>
- [7] Li, Y., Luo, Y., Zheng, Y., Liu, G., & Gong, J. (2024). Research on Target Image Classification in Low-Light Night Vision. Entropy, 26(10). <https://doi.org/10.3390/e26100882>